

MD RAKIBUL ISLAM RAIHAN

raihanrakib.143@gmail.com | +86-17722362949 | WeChat: imeddi | linkedin.com/in/theraihanrakib
Xi'an, China | Bangladesh | MBTI: ENTJ | English (Fluent, IELTS 8.0) | Chinese (Conversational, HSK 3)



PROFESSIONAL SUMMARY

MS candidate (Top 1%) with production experience optimizing LLM inference. Achieved 8.3x TTFT reduction and 98% cache hit rates on 8xH200 clusters. Expert in SGLang, CUDA, Triton, and distributed systems.

OPEN TO: Algorithm Engineer – AI Infra | AI Product Manager

TECHNICAL SKILLS

Inference: SGLang, vLLM, TensorRT-LLM, Transformer Engine, Mooncake RDMA
Optimization: PD Disaggregation, HiCache, FP8/FP4, QAT, Block-Wise Scaling
Kernel: CUDA, Triton, Nsight Systems/Compute, PyTorch Profiler, Perfetto
ML/DL: PyTorch, TensorFlow, Transformers, Diffusion (DiT), GANs
Languages: Python (Expert), C++, Java, SQL, MATLAB
Data/Cloud: Spark, Hadoop, AWS, GCP, Docker, Git
Embedded: PLC (Codesys), Modbus, CAN, Ethernet/IP, IEC 61131
Product: Agile/Scrum, JIRA, Cross-functional Leadership, Technical Writing

EXPERIENCE

Technical Staff Intern – AI Infra | InfiX.ai | Shenzhen, China | Apr 2026 – Jun 2026

- Optimized LLM inference with SGLang/Mooncake RDMA on A800/H200 GPUs
- Implemented HiCache → 98% hit rate, 8.3x faster TTFT (55s→6.7s) at 85-95 Gbps
- Designed PD-disaggregated inference across 2xA800 & 8xH200 clusters
- Profiled workloads → identified GEMM kernels (60% runtime) as bottleneck
- Developed FP8 quantization + LRU/LFU/SLRU policies; resolved 12 bugs
- Proved LFU > LRU at 90%+ hit rates across 4M+ tokens (Qwen/DeepSeek)

Software Engineer – AI Agent Platform | Amraim Group | Shenzhen, China | Jun 2025 – Sep 2025

- Architected AI agents automating workflows → 25% productivity boost
- Delivered 2 full-stack apps (React + RESTful APIs) concept to production
- Led Agile/Scrum SDLC for secure, scalable enterprise solutions

Electrical Software Engineer – Robotics | Shaanxi Longong Intelligent Technology | Xi'an, China | Feb 2025 – Apr 2025

- Optimized motor control algorithms → 15% faster response, higher throughput
- Developed embedded firmware: PLC (Codesys), Modbus, CAN, Ethernet/IP
- Designed electrical schematics with IEC 61131 compliance

Graduate Research Assistant – Multimodal AI | Northwestern Polytechnical University | Xi'an, China | Sep 2024 – Jul 2027

- Built text-to-video pipeline using Diffusion Transformers → 90% satisfaction
- Thesis: Multimodal Deepfake Detection using Visual, Auditory, Temporal Inconsistencies

Undergraduate Research Intern – HPC | Northwestern Polytechnical University | Xi'an, China | Jan 2023 – Jul 2024

- Designed confidential query protocol on Spark with homomorphic encryption
- Achieved 95% confidentiality, 20% faster than baseline

EDUCATION

M.Eng. Software Engineering | Northwestern Polytechnical University (985/211) | 2024–2027 | GPA: 88/100 | Top 1%

B.Eng. Computer Science | Northwestern Polytechnical University (985/211) | 2020–2024 | GPA: 85/100 | Top 1%

Awards: Chinese Government Scholar | Presidential Scholar | Outstanding Graduate

PROJECTS

- Multimodal Text-to-Video Generation: DiT + GAN, cross-modal alignment, 90% satisfaction, AWS deployed
- GAN-Based Medical Image Enhancement: MRI super-resolution → 85% tumor detection accuracy
- Real-Time UAV Visual Tracking: Deep learning tracker → 95% IoU on BAIR dataset
- Distributed Confidential Query Protocol: Spark + homomorphic encryption → 95% confidentiality

CERTIFICATIONS & LEADERSHIP

Certifications: AWS ML Specialty | Deep Learning Specialization | PSM I

Leadership: Director, Intl Students Union (2023) | Hackathon Winner (2022)

Awards: Best Thesis Award | Sanqin Scholar | Wu Yajun Scholar

MD RAKIBUL ISLAM RAIHAN (杨瀚)

raihanrakib.143@gmail.com | +86-17722362949 | 微信: imeddi | linkedin.com/in/theraihanrakib
中国西安 | 孟加拉国 | MBTI: ENTJ | 英语 (流利, 雅思 8.0) | 中文 (日常交流, HSK 3 级)



个人简介

软件工程硕士研究生 (专业前 1%), 具备 LLM 推理优化生产经验。实现 8.3 倍首令牌时延优化及 8xH200 集群 98%缓存命中率。精通 SGLang、CUDA、Triton 及分布式系统。

求职方向: 算法工程师 – AI 基础设施 | AI 产品经理

专业技能

推理优化: SGLang, vLLM, TensorRT-LLM, Transformer Engine, Mooncake RDMA
性能优化: PD 分离推理, HiCache 分层缓存, FP8/FP4 量化, QAT, 分块缩放
内核开发: CUDA, Triton, Nsight Systems/Compute, PyTorch Profiler, Perfetto
深度学习: PyTorch, TensorFlow, Transformers, 扩散模型(DiT), GANs
编程语言: Python (精通), C++, Java, SQL, MATLAB
数据与云: Spark, Hadoop, AWS, GCP, Docker, Git
嵌入式系统: PLC (Codesys), Modbus, CAN, Ethernet/IP, IEC 61131
产品管理: Agile/Scrum, JIRA, 跨职能领导, 技术写作

工作经历

AI 基础设施技术实习生 | 无界智索(深圳)科技有限责任公司 | 中国深圳 | 2026 年 4 月 – 2026 年 6 月

- 使用 SGLang/Mooncake RDMA 在 A800/H200 GPU 上优化 LLM 推理服务
- 实现 GPU/CPU/SSD 三层 HiCache 缓存 → 98%命中率, 8.3 倍 TTFT 加速 (55s→6.7s)
- 设计 2xA800 及 8xH200 集群的 PD 分离推理系统
- 性能剖析 → 识别 GEMM 内核 (占运行时间 60%) 为性能瓶颈
- 开发 FP8 量化及混合缓存策略 (LRU/LFU/SLRU); 解决 12 个生产环境缺陷
- 证明 LFU 策略优于 LRU, 在 400 万+ tokens 上实现 90%+缓存命中率 (Qwen/DeepSeek)

AI 智能体平台软件工程师 | 香港安莱姆集团有限公司 | 中国深圳 | 2025 年 6 月 – 2025 年 9 月

- 设计 AI 智能体自动化营销工作流 → 团队效率提升 25%
- 从概念到生产交付 2 个全栈应用 (React + RESTful API)
- 主导 Agile/Scrum 全流程开发, 确保安全、可扩展的企业级解决方案

机器人电气软件工程师 | 陕西龙宫智能科技有限公司 | 中国西安 | 2025 年 2 月 – 2025 年 4 月

- 优化实时电机控制算法 → 响应速度提升 15%, 吞吐量提升
- 开发嵌入式固件: PLC (Codesys), Modbus, CAN, Ethernet/IP
- 设计符合 IEC 61131 标准的电气原理图

多模态 AI 研究生助理 | 西北工业大学 | 中国西安 | 2024 年 9 月 – 2027 年 7 月

- 基于 Diffusion Transformers 构建文生视频 pipeline → 90%用户满意度
- 论文: 基于视觉、听觉和时间一致性的多模态深度伪造检测

高性能计算本科生研究实习生 | 西北工业大学 | 中国西安 | 2023 年 1 月 – 2024 年 7 月

- 设计基于 Spark 的同态加密机密查询协议
- 实现 95%数据机密性, 性能较基线提升 20%

教育背景

软件工程硕士 | 西北工业大学 (985/211) | 2024–2027 | GPA: 88/100 | 专业前 1%

计算机科学与技术学士 | 西北工业大学 (985/211) | 2020–2024 | GPA: 85/100 | 专业前 1%

荣誉: 中国政府奖学金 | 校长奖学金 (连续 3 年) | 优秀毕业生

项目经历

- 多模态文生视频生成: DiT + GAN, 跨模态对齐, 90%满意度, AWS 部署
- 基于 GAN 的医学图像增强: MRI 超分辨率重建 → 肿瘤检测准确率提升至 85%
- 无人机实时视觉跟踪: 深度学习跟踪器 → BAIR 数据集 95% IoU 准确率
- 分布式机密查询协议: Spark + 同态加密 → 95%机密性保障

证书与领导力

证书: AWS 机器学习专项认证 | 深度学习专项课程 | PSM I 敏捷项目管理认证

领导力: 国际学生会主席 (2023) | 黑客松大赛冠军 (2022)

荣誉: 优秀毕业论文奖 | 三秦奖学金 | 吴亚军奖学金