

MD RAKIBUL ISLAM RAIHAN

Date of Birth: 2002.12.06

Email: raihanrakib.143@gmail.com

Phone: +86-17722362949

WeChat: imeddii

Address: Mainland China

Nationality: Bangladesh

MBTI: ENTJ

Languages: English (Fluent, IELTS 8.0), Chinese (Conversational, HSK 3)

LinkedIn: <https://www.linkedin.com/in/theraihanrakib>

Portfolio: <https://theraihanrakibb.github.io/Online-Portfolio/>

Seeking Positions: AI Engineer (AI Infra) | AI Product Manager (AI Infra)



Objective

Master's candidate in Software Engineering (**top 1% of program**) with current industry experience designing **NVFP4 pretraining pipelines for LLMs and VLMs**, optimizing inference serving (**SGLang, vLLM, TensorRT-LLM, Transformer Engine**), and developing **custom CUDA/Triton kernels** for mixed-precision training.

Research focuses on **multimodal AI, generative models (Diffusion, GANs)**, and **audio-visual fusion** — from fundamentals to deployment. Proficient in **PyTorch, TensorFlow**, and **Apache Spark** for large-scale data processing. Previously led an **end-to-end text-to-video generation pipeline** in an academic lab and delivered **full-stack AI Agent solutions** with commercial deployment.

Committed to advancing foundation models and multimodal algorithms. Seeking **AI Engineer (AI Infra)** or **AI Product Manager (AI Infra)** role bridging cutting-edge research and real-world products to drive impactful innovation.

Education

Master of Engineering in Software Engineering

Northwestern Polytechnical University, Xi'an, China (**QS #499, 985, 211, E9 League**)

Sep 2024 – Mar 2027

- **GPA:** 88/100
- **Rank:** 1%
- **Relevant Coursework:** Machine Learning, Computer Vision, Natural Language Processing, Software Project Management.
- **Extracurricular Activities:** Member of Student Union, Academic Mentor, Teaching Assistant.
- **Research:** "Multimodal Video Generation: Integrating Audio and Visual Signals for Realistic Content Creation" (Under the guidance of Dr. Zhang Peng).
- **Thesis:** "Detecting Deepfake Videos: A Multimodal AI Framework Leveraging Visual, Auditory, and Temporal Inconsistencies." (Under the guidance of Dr. Zhang Peng).

Bachelor of Engineering in Computer Science and Technology

Northwestern Polytechnical University, Xi'an, China (**QS #499, 985, 211, E9 League**)

Sep 2020 – Jul 2024

- **GPA:** 85/100
- **Rank:** 1%
- **Outstanding Undergraduate Graduate (Top 10)** ([link](#))
- **Relevant coursework:** Algorithms, Data Structures, Software Engineering, Database Systems.
- **Extracurricular Activities:** Director of International Student Union (2023), Academic Volunteer (2023,2024)

- **Thesis:** “Design and implemented a Distributed Confidential Query Protocol for Apache Spark.” (Under the guidance of Dr. Chen Yaxing).
-

Experience

Graduate Research Assistant

Multimodal Learning and Video Generation Lab, NWPU

Sep 2024 – Mar 2027

Advisor: Dr. Zhang Peng

- Spearheaded research in **audio-visual fusion models** to enhance the realism and synchronization of generated video content.
- Designed and implemented a novel **self-supervised learning framework** for cross-modal representation learning, improving alignment between audio and visual data streams.
- Engineered an end-to-end **text-to-video generation pipeline** leveraging Transformer-based architectures (e.g., Diffusion Transformers) to convert semantic prompts into dynamic visual sequences.

Undergraduate Research Intern

High Performance Computing Lab, NWPU

Jan 2023 – Jul 2024

Advisor: Dr. Chen Yaxing

- Researched and implemented a **Distributed Confidential Query Protocol**, designing mechanisms for secure, privacy-preserving data retrieval across distributed nodes.
 - Developed large-scale data processing modules for a **cloud computing and networking project** using **Apache Spark and SQL**, optimizing query performance on distributed datasets.
-

Internship

Technical Staff Intern – AI Infra

[InfiX.ai](#) LIMITED

Apr 2026 – Jun 2026

- Optimized LLM inference serving using SGLang and Mooncake RDMA on A800/H200 GPUs, implementing hierarchical KV cache (HiCache) with GPU/CPU/SSD tiering to improve throughput and latency.
- Developed custom configuration strategies for FP8 quantization and hybrid cache policies (LRU, LFU, SLRU), uncovering and resolving silent dependency issues where FP8 required HiCache activation.
- Profiled distributed inference workloads using PyTorch Profiler and Perfetto, identifying GEMM kernels (60% of runtime) as the true bottleneck—not cache I/O—redirecting optimization focus for maximum impact.
- Designed and benchmarked prefill-decode (PD) disaggregated inference system across 2x A800 and 8x H200 clusters, achieving 98% cache hit rate and 8.3x faster TTFT (55s to 6.7s) with Mooncake RDMA at 85-95 Gbps.
- Validated cache performance and convergence across multiple configurations (TP2/DP2, with/without HiCache, BF16 vs FP8), documenting 12 production bugs including DP2 tensor misalignment crashes and Mooncake port mismatches.
- Collaborated on eviction policy evaluation for hybrid attention models (Qwen3.5-27B, Qwen3.6-27B, DeepSeek-V3.2), proving LFU outperforms LRU for multi-turn workloads at 90%+ cache hit rates across 4M+ tokens.

Software Engineer – AI Agent

[Hong Kong Amraim Group Co., Ltd.](#)

Jun 2025 – Sep 2025

- Engineered intelligent AI agents that automated key marketing workflows, reducing manual effort and boosting team productivity by 25%.
- Architected and delivered two end-to-end full-stack applications from concept to deployment, directly addressing core business requirements and user needs.
- Built dynamic, responsive front-end interfaces using React and developed scalable back-end services with RESTful APIs to seamlessly integrate AI/ML features.

- Drove the full software development lifecycle in an Agile (Scrum) environment, from planning to deployment, ensuring the delivery of secure, scalable, and production-ready solutions.

Electrical Software Engineer – Algorithms

[Shaanxi Longong Intelligent Technology Co., Ltd.](#)

Feb 2025 – Apr 2025

- Engineered and optimized real-time motor control algorithms for industrial automation machinery, improving system response time by 15% and increasing overall throughput.
- Developed, debugged, and validated embedded control software utilizing PLC programming (Codesys) and industrial communication protocols (Modbus, CAN, Ethernet/IP) to ensure reliable system operation.
- Designed electrical schematics and led prototyping for hardware-software interfaces in new automation equipment, ensuring full compliance with industry safety and regulatory standards (e.g., IEC 61131).
- Collaborated within a cross-functional R&D team using Agile (Scrum) methodologies; managed project tasks in JIRA and maintained version control with Git to streamline the development lifecycle.

Professional & Technical Skills

✧ AI/ML & Deep Learning

PyTorch • TensorFlow • Keras • Transformer Architectures • Self-Supervised & Multimodal Learning • Audio-Visual Fusion • Generative Models (Diffusion) • NVFP4 Low-Precision Training • vLLM • TensorRT-LLM • Transformer Engine • Quantization-Aware Training (QAT) • Block-Wise Scaling

✧ Systems & High-Performance Computing

CUDA • SGLang • Triton (Kernel Development) • NVIDIA Nsight Systems • NVIDIA Nsight Compute • Mixed-Precision Training • Distributed Model Fusion • FP8/FP4 Optimization

✧ Programming & Data Engineering

Python (Proficient) • C++ • Java • SQL • MATLAB • Apache Spark • Hadoop • Hive • RESTful APIs

✧ Cloud, MLOps & Embedded Systems

AWS • Google Cloud Platform (GCP) • Docker • Git • Embedded Systems (PLC, Codesys, Modbus/CAN/Ethernet/IP)

✧ Methodologies & Core Competencies

Agile/Scrum Project Management • Cross-Functional Collaboration • Full Software/Research Lifecycle • Technical Research & Writing • Complex Problem-Solving • Electrical Prototyping & Safety Compliance • Performance Profiling & Debugging

Projects

1. Alcohol Detection System for Automobiles | *Embedded IoT Project*

- Engineered a real-time alcohol detection prototype for automotive safety using an IR sensor and an Arduino/ESP32 microcontroller.
- Developed the sensor data processing firmware and a threshold-based alert system to trigger warnings upon detection.
- Designed the hardware interface and enclosure, ensuring reliability for in-vehicle environmental conditions.

2. Distributed Confidential Query Protocol for Apache Spark | *Privacy-Preserving Big Data*

- Designed and implemented a secure, privacy-preserving query execution engine for Apache Spark using homomorphic encryption.
- Maintained 95% data confidentiality with minimal performance overhead during testing on a 10-node cluster.
- Optimized distributed query performance by 20% compared to baseline privacy frameworks.

3. Multimodal Text-to-Video Generation Tool | *Generative AI Research*

- Built an end-to-end text-to-video generation pipeline using Diffusion Transformer (DiT) architectures and GAN components.
- Integrated cross-modal (audio-visual) alignment techniques, with generated outputs achieving 90% user satisfaction in qualitative evaluations.

- Deployed the scalable inference service on AWS EC2 & S3, enabling on-demand video synthesis.

4. GAN-Based Medical Image Enhancement | *Healthcare AI Application*

- Developed a conditional GAN model to super-resolve and denoise low-resolution MRI scans, enhancing clinical detail.
- The enhanced images improved downstream tumor detection accuracy to 85% when validated with a standard segmentation model.

5. Real-Time Visual Object Tracking for UAVs | *Computer Vision & Autonomous Systems*

- Designed and trained a deep learning-based visual tracking system for unmanned aerial vehicles (UAVs) in dynamic environments.
- Achieved 95% tracking accuracy (IoU) when evaluated on the BAIR Robot Pushing Dataset, demonstrating robustness to occlusion.

Certifications

- **AWS Certified Machine Learning – Specialty | Amazon Web Services**
(Validates ability to ship production ML solutions on a major cloud platform)
- **Deep Learning Specialization | [DeepLearning.AI](#) (Coursera)**
(Certifies core AI/ML knowledge for informed technical decision-making and roadmap planning)
- **Agile & Product Methodology**
Professional Scrum Master I (PSM I) | [Scrum.org](#)
(Demonstrates formal Agile/Scrum expertise for leading technical teams and managing development cycles)

Awards and Achievements

Scholarships & Academic Honors

- Chinese Government Scholarship (2024 – 2026 | Awarded for academic excellence)
- NWPU Presidential Scholarship (2020 – 2023 | Awarded consecutively for top-tier academic performance)
- Sanqin Scholarship (2023 | Merit-based award for outstanding research potential)
- Wu Yajun Scholarship (2024 | Merit-based award for outstanding research potential)

Leadership & Service

- Director, International Students Union (2023 | Led initiatives and represented a diverse student body)
- Academic Volunteer (2022 – 2023 | Assisted in tutoring and research support for underclassmen)

Competitions & Recognition

- Hackathon Winner, NWPU AI Challenge (2022 | Led team to victory in 48-hour applied AI competition)
- Best Undergraduate Thesis Award – *Distributed Confidential Query Protocol for Spark* (Awarded for top research contribution and implementation)

杨瀚

出生日期：2002.12.06

邮箱：raihanrakib.143@gmail.com

电话：+86-17722362949

微信：imeddi

地址：中国大陆

国籍：孟加拉国

MBTI 类型：ENTJ (指挥官型)

语言：英语（流利，雅思 8.0），中文（日常交流，HSK 3 级）

领英：<https://www.linkedin.com/in/theraihanrakib>

作品集：<https://theraihanrakibb.github.io/Online-Portfolio/>

求职意向：AI 基础设施工程师 | AI 基础设施产品经理



目标

软件工程硕士研究生（专业排名前 1%），具备当前行业经验，设计 NVFP4 预训练流水线用于大语言模型和视觉语言模型，优化推理服务（SGLang、vLLM、TensorRT-LLM、Transformer Engine），并为混合精度训练开发定制 CUDA/Triton 内核。

研究方向聚焦多模态 AI、生成模型（扩散模型、生成对抗网络）以及音视频融合——从基础理论到实际部署。熟练掌握 PyTorch、TensorFlow 及大规模数据处理工具 Apache Spark。曾在学术实验室主导端到端文本生成视频流水线的设计，并交付了具备商业部署能力的全栈 AI 智能体解决方案。

致力于推进基础模型与多模态算法的发展。寻求 AI 基础设施工程师或 AI 基础设施产品经理岗位，结合前沿研究与实际产品，推动有影响力的创新。

教育背景

软件工程硕士

西北工业大学，西安 中国 (QS 全球排名第 499 位 · 985 工程 · 211 工程 · 卓越联盟成员)

2024 年 9 月 – 2027 年 3 月

- GPA：88/100
- 排名：1%
- 相关课程：机器学习、计算机视觉、自然语言处理、软件项目管理。
- 课外活动：学生会成员、学业导师、助教。
- 研究：《多模态视频生成：整合音频与视觉信号以实现真实内容创作》（在张蓬博士指导下）。
- 论文：“检测深度伪造视频：利用视觉、听觉和时间不一致的多模态人工智能框架。”（在张蓬博士指导下）

计算机科学与技术工程学士

西北工业大学，西安 中国 (QS 全球排名第 499 位 · 985 工程 · 211 工程 · 卓越联盟成员)

2020 年 9 月 – 2024 年 7 月

- GPA：85/100
- 排名：1%
- 优秀本科毕业生（前十名）([链接](#))

- **相关课程：**算法、数据结构、软件工程、数据库系统。
- **课外活动：**国际学生会主任（2023 年）、学术志愿者（2023 年、2024 年）
- **论文：**“设计并实现了 Apache Spark 的分布式机密查询协议。”（在陈亚兴博士指导下）

经历

研究生助理

多模态学习与视频生成实验室，西北工业大学

2024 年 9 月 – 2027 年 3 月

导师：张蓬博士

- 主导了**视听融合模型**的研究，以提升生成视频内容的真实性和同步性。
- 设计并实施了一种创新的**自监督学习框架**，用于跨模态表示学习，改善了音频和视觉数据流之间的对齐。
- 利用基于 Transformer 的架构（如 Diffusion Transformers）**设计了端到端文本到视频生成流程**，将语义提示转换为动态视觉序列。

本科生研究实习生

西北工业大学高性能计算实验室

2023 年 1 月 – 2024 年 7 月

导师：陈雅兴博士

- 研究并实施了**分布式机密查询协议**，设计了跨分布节点安全、保护隐私的数据检索机制。
- 为云计算和网络项目开发了**大规模数据处理模块**，利用 **Apache Spark** 和 **SQL** 优化分布式数据集的查询性能。

实习经历

技术员工实习生 – AI 基础设施

[InfiX.ai](#) LIMITED (无界智索(深圳)科技有限责任公司)

2026 年 4 月 – 2026 年 6 月

- 使用 SGLang 和 Mooncake RDMA 在 A800/H200 GPU 上优化 LLM 推理服务，实现基于 GPU/CPU/SSD 分层的层次化 KV 缓存 (HiCache)，显著提升吞吐量并降低延迟。
- 针对 FP8 量化及混合缓存策略 (LRU、LFU、SLRU) 开发定制化配置方案，发现并解决了 FP8 必须依赖 HiCache 激活才能生效的隐性依赖问题。
- 使用 PyTorch Profiler 和 Perfetto 对分布式推理负载进行性能剖析，确定 GEMM 核函数（占运行时间 60%）是真正的性能瓶颈，而非缓存 I/O，从而将优化工作聚焦于高回报方向。
- 设计并测试了跨 2× A800 和 8× H200 集群的预填充-解码 (PD) 分离推理系统，在 Mooncake RDMA (85–95 Gbps) 下实现了 98% 的缓存命中率和 8.3 倍的首令牌时延 (TTFT) 优化 (55s → 6.7s)。
- 在多种配置下 (TP2/DP2、是否启用 HiCache、BF16 vs FP8) 验证缓存性能与收敛性，记录了 12 个生产环境缺陷，包括 DP2 张量对齐错误导致的崩溃及 Mooncake 端口配置错误。
- 针对混合注意力模型 (Qwen3.5-27B、Qwen3.6-27B、DeepSeek-V3.2) 协作评估缓存淘汰策略，证明在多线程对话场景下 LFU 策略优于 LRU，在 400 万以上 token 规模下实现 90%+ 缓存命中率。

软件工程师 – AI 智能体

[Hong Kong Amraim Group Co., Ltd.](#) (香港安莱姆集团有限公司)

2025 年 6 月 – 2025 年 9 月

- 设计了智能人工智能代理，自动化关键营销工作流程，减少人工工作，提升团队生产力 25%。

- 从构想到部署，构建并交付了两个端到端的全栈应用，直接满足核心业务需求和用户需求。
- 利用 React 构建了动态响应式的前端接口，并开发了可扩展的后端服务，采用 RESTful API，实现了 AI/ML 功能的无缝集成。
- 在敏捷（Scrum）环境中推动整个软件开发生命周期，从规划到部署，确保安全、可扩展且具备生产环境的解决方案交付。

电气软件工程师

[Shaanxi Longong Intelligent Technology Co., Ltd.](#) (陕西龙宫智能科技有限公司)

2025 年 2 月– 2025 年 4 月

- 为工业自动化机械设计并优化了实时电机控制算法，提高了系统响应时间 15%，提高了整体吞吐量。
- 开发、调试并验证嵌入式控制软件，采用 PLC 编程（Codesys）和工业通信协议（Modbus、CAN、以太网/IP），以确保系统运行的可靠性。
- 设计了新型自动化设备硬件-软件接口的电气原理图和铅成型，确保完全符合行业安全和监管标准（如 IEC 61131）。
- 在一个跨职能研发团队中合作，采用敏捷（Scrum）方法；管理 JIRA 中的项目任务，并用 Git 维护版本控制，以简化开发生命周期。

专业与技术技能

✧ AI/ML 与深度学习

PyTorch • TensorFlow • Keras • Transformer 架构 • 自监督与多模态学习 • 音视频融合 • 生成模型（扩散模型）
• NVFP4 低精度训练 • vLLM • TensorRT-LLM • Transformer Engine • 量化感知训练（QAT） • 分块缩放策略

✧ 系统与高性能计算

CUDA • SGLang • Triton（内核开发） • NVIDIA Nsight Systems • NVIDIA Nsight Compute • 混合精度训练 • 分布式模型融合 • FP8/FP4 优化

✧ 编程与数据工程

Python（熟练） • C++ • Java • SQL • MATLAB • Apache Spark • Hadoop • Hive • RESTful API

✧ 云、MLOps 与嵌入式系统

AWS • 谷歌云平台（GCP） • Docker • Git • 嵌入式系统（PLC、Codesys、Modbus/CAN/Ethernet/IP）

✧ 方法与核心能力

Agile/Scrum 项目管理 • 跨部门协作 • 完整软件/研究生命周期 • 技术与写作 • 复杂问题解决 • 电气原型开发与安全合规 • 性能分析与调试

项目

1. 汽车酒精检测系统 | 嵌入式物联网项目

- 设计了一款用于汽车安全的实时酒精检测原型，使用红外传感器和 Arduino/ESP32 微控制器。
- 开发了传感器数据处理固件和基于阈值的警报系统，以在检测到时触发警告。
- 设计了硬件接口和外壳，确保车载环境下的可靠性。

2. Apache Spark 分布式机密查询协议 | 保护隐私的大数据

- 设计并实现了一个安全、保护隐私的 Apache Spark 查询执行引擎，采用同态加密。
- 在 10 节点集群测试期间，保持 95% 的数据机密性，性能开销极低。
- 与基线隐私框架相比，分布式查询性能优化了 20%。

3. 多模态文本转视频生成工具 | 生成式人工智能研究

- 利用扩散变换器 (DiT) 架构和 GAN 组件构建了端到端的文本到视频生成流水线。
- 集成跨模态 (视听) 对齐技术, 生成的输出在定性评估中达到 90% 的用户满意度。
- 在 AWS EC2 和 S3 上部署了可扩展推理服务, 支持按需视频合成。

4. 基于 GAN 的医学图像增强 | 医疗人工智能应用

- 开发了条件性 GAN 模型, 用于超解析和去噪低分辨率 MRI 扫描, 提升临床细节。
- 经过标准分割模型验证后, 增强后的图像将下游肿瘤检测准确率提升至 85%。

5. 无人机实时视觉物体跟踪 | 计算机视觉与自主系统

- 设计并训练了一套基于深度学习的无人机视觉跟踪系统, 适用于动态环境中的无人机 (UAV)。
- 在 BAIR 机器人推力数据集上评估时, 实现了 95% 的跟踪准确率 (IoU), 展现出对遮挡的鲁棒性。

认证

- AWS 认证机器学习——专业 | 亚马逊网络服务
(验证在主要云平台上发布生产型机器学习解决方案的能力)
- 深度学习专业 | [DeepLearning.AI](#) (Coursera)
(认证核心 AI/机器学习知识, 用于有根据的技术决策和路线规划)
- 敏捷与产品方法论
专业 Scrum Master I (PSM I) | [Scrum.org](#)
(展示领导技术团队和管理开发周期的正式敏捷/Scrum 专业知识)

奖项与成就

奖学金与学术荣誉

- 中国政府奖学金 (2024 – 2026 | 以表彰学业卓越)
- NWPU 总统奖学金 (2020 – 2023 | 连续颁发, 表彰顶尖学业表现)
- 三秦奖学金 (2023 年 | 基于优秀科研潜力的奖学金)
- 吴亚军奖学金 (2024 年 | 基于优秀研究潜力的优异奖)

领导与服务

- 国际学生联盟主任 (2023 | 领导各项倡议, 代表多元化的学生群体)
- 学术志愿者 (2022 – 2023 | 协助辅导和支持低年级学生的研究)

竞赛与荣誉

- 黑客松获奖者, NWPU AI 挑战赛 (2022 年 | 带领团队赢得了 48 小时应用人工智能竞赛的胜利)
- 最佳本科生论文奖——*Spark* 分布式机密查询协议 (表彰其卓越研究贡献和实施)