

MD RAKIBUL ISLAM RAIHAN

AI Infrastructure Engineer | LLM Inference Systems | GPU Optimization

Email: raihanrakib.143@gmail.com | Phone: +86-17722362949 | Location: Xi'an, China

LinkedIn: <https://www.linkedin.com/in/theraihanrakib>

GitHub: <https://github.com/theraihanrakibb>

Portfolio: <https://theraihanrakibb.github.io/Online-Portfolio/>

Nationality: Bangladesh | Languages: English (Fluent), Chinese (Conversational)



SUMMARY

M.Eng. Software Engineering student (Top 1%) specializing in LLM inference systems, distributed serving, and GPU optimization. Experienced with SGLang, CUDA, Triton, Mooncake RDMA, and multi-GPU inference on A800/H200 clusters. Designed production KV-cache architectures achieving **92.27% cache hit rates** and **8.3× TTFT reduction** on multi-GPU inference systems. First author of an **IEEE Transactions on Multimedia (TMM)** paper under review.

EXPERIENCE

AI Infrastructure Engineer Intern | InfiX.ai | Shenzhen, China | Apr 2026 – Jun 2026

- Patched SGLang source code across cache management and memory allocation modules (**kvcacheio.py**, **hiradix_cache.py**, **memory_pool_host.py**) to resolve production cache failures and support deployment of hybrid-attention Qwen models on **4× A800 GPU clusters**.
- Designed a **3-tier KV-cache architecture (GPU HBM → CPU DRAM → SSD)** using SGLang and Mooncake RDMA, achieving **92.27% cache hit rate** and reducing **TTFT by 8.3× (55s → 6.7s)**.
- Applied **Little's Law** to determine infrastructure capacity limits, proving long-context workloads were constrained to **~1.5 RPS** on 4× A800-80GB systems.
- Profiled CUDA/Triton inference pipelines with Nsight Systems, identifying GEMM bottlenecks and improving serving efficiency through kernel optimization and FP8 quantization.
- Built PD-disaggregated serving architecture with RDMA-based KV sharing, increasing stable concurrency from **192 to 256 requests**.
- Diagnosed and resolved **12+ production issues** involving RDMA, etcd, networking, storage, and distributed inference systems.

Software Engineer Intern (AI Agent) | Hong Kong Amram Group | Shenzhen, China | Jun 2025 – Sep 2025

- Developed production full-stack applications using React, REST APIs, and backend automation services.
- Built AI-agent workflow automation systems that improved operational efficiency by **25%**.

Electrical Software Engineer Intern | Shaanxi Longong Intelligent Technology | Xi'an, China | Feb 2025 – Apr 2025

- Developed PLC-based industrial control systems using CODESYS for robotics and industrial automation.
- Implemented Modbus, CAN, and Ethernet/IP communication protocols, improving motor-control performance by **15%**.

RESEARCH

Graduate Researcher | Northwestern Polytechnical University | Sep 2024 – Present

- Developed **NVFP4-DiT**, a 4-bit audio-guided video diffusion transformer achieving **4× memory reduction** while maintaining generation quality.
- Implemented low-precision quantization techniques for multimodal diffusion transformers and evaluated quality-efficiency trade-offs.
- First author of "*NVFP4-DiT: Efficient 4-Bit Audio-Guided Video Diffusion Transformers for Low-Cost Video Generation*" (**IEEE Transactions on Multimedia**, under review).
- Conducting research on multimodal deepfake detection using visual, audio, and temporal consistency analysis.
- M.Eng. Thesis: "*Detecting Deepfake Videos: A Multimodal AI Framework Leveraging Visual, Auditory, and Temporal Inconsistencies*"

Undergraduate Researcher | Northwestern Polytechnical University | Jan 2023 – Jul 2024

- Designed a distributed confidential-query framework using Apache Spark and CKKS homomorphic encryption.
- Achieved **95% privacy preservation** and **20% performance improvement** through optimized analytics pipelines.
- B.Eng. Thesis: "*Design and Implementation of a Distributed Confidential Query Protocol for Apache Spark*"

TECHNICAL SKILLS

Languages: Python, C++, Java, SQL, Bash

LLM Systems: SGLang, vLLM, TensorRT-LLM, KV Cache Design, PD Disaggregation, Mooncake RDMA, etcd, NATS

GPU & ML Systems: CUDA, Triton, FlashAttention-2/3, FP8/FP4 Quantization, GEMM Optimization, Nsight Systems, Nsight Compute

Infrastructure: Linux, Docker, Kubernetes, Slurm, RDMA Networking, TCP/IP, Prometheus, Grafana, Git, CI/CD

EDUCATION

M.Eng. Software Engineering | Northwestern Polytechnical University (985/211) | Sep 2024 – Mar 2027

- GPA: **88/100 | Top 1%** | Chinese Government Scholarship

B.Eng. Computer Science & Technology | Northwestern Polytechnical University (985/211) | Sep 2020 – Jul 2024

- GPA: **85/100 | Top 1%** | Presidential Scholarship | Best Undergraduate Thesis Award

PUBLICATIONS & HONORS

Publication

- First Author, "*NVFP4-DiT: Efficient 4-Bit Audio-Guided Video Diffusion Transformers for Low-Cost Video Generation*" — **IEEE Transactions on Multimedia (TMM, Q1)**, Under Review

Honors

- Chinese Government Scholarship (2024–2026)
- Presidential Scholarship (2020–2023)
- Best Undergraduate Thesis Award
- Outstanding Graduate, Northwestern Polytechnical University
- Hackathon Winner — NWPU AI Challenge

MD RAKIBUL ISLAM RAIHAN (杨瀚)

人工智能基础设施工程师 | 大语言模型推理系统 | GPU 性能优化

邮箱: raihanrakib.143@gmail.com | 电话: +86-17722362949 | 所在地: 中国西安

LinkedIn: <https://www.linkedin.com/in/theraihanrakib>

GitHub: <https://github.com/theraihanrakibb>

作品集: <https://theraihanrakibb.github.io/Online-Portfolio/>

国籍: 孟加拉国 | 语言: 英语 (流利), 中文 (日常会话)



摘要

工程硕士, 软件工程学生 (前 1%), 专攻 LLM 推理系统、分布式服务和 GPU 优化。我有使用 SGLang、CUDA、Triton、Mooncake RDMA 以及 A800/H200 集群上的多 GPU 推理经验。设计了生产型 KV 缓存架构, 在多 GPU 推理系统中实现了 **92.27% 的缓存命中率**和 **8.3 倍的 TTFT 降低**。一篇正在审阅的 **IEEE 多媒体汇刊 (TMM)** 论文的第一作者。

经历

人工智能基础设施工程师实习生 | 无界智索(深圳)科技有限责任公司 | 中国深圳 | 2026 年 4 月 – 2026 年 6 月

- 对 SGLang 源代码进行了跨缓存管理和内存分配模块 (`kvcacheio.py`, `hiradix_cache.py`, `memory_pool_host.py`) 的补丁, 以解决生产缓存故障并支持在 **4× 台 A800 GPU 集群上部署混合注意力 Qwen 型号**。
- 设计了三层 KV 缓存架构 (**GPU HBM → CPU DRAM → SSD**), 采用 SGLang 和 Mooncake RDMA, 实现了 **92.27% 的缓存命中率**, 并将 TTFT 降低了 **8.3× (55 秒 → 6.7 秒)**。
- 应用利特尔定律确定基础设施容量限制, 证明长上下文工作负载在 **4× A800-80GB 系统上**限制在约 1.5 RPS。
- 与 Nsight Systems 合作分析 CUDA/Triton 推理流水线, 识别 GEMM 瓶颈, 并通过核优化和 FP8 量化提升服务效率。
- 构建了基于 RDMA 的 KV 共享的 PD 拆分服务架构, 将稳定并发量从 **192 个提升到 256 个**。
- 诊断并解决了涉及 RDMA、etcd、网络、存储和分布式推理系统的 12+ 生产问题。

软件工程师实习生 (AI 代理) | 香港阿姆兰集团 | 中国深圳 | 2025 年 6 月 – 2025 年 9 月

- 开发了使用 React、REST API 和后端自动化服务的生产全栈应用。
- 构建了人工智能代理工作流程自动化系统, 使运营效率提升了 **25%**。

电气软件工程师实习生 | 陕西龙功智能技术 | 中国西安 | 2025 年 2 月 – 2025 年 4 月

- 利用 CODESYS 开发基于 PLC 的工业控制系统, 用于机器人和工业自动化。
- 实现了 Modbus、CAN 和以太网/IP 通信协议, 使电机控制性能提升了 **15%**。

研究

研究生研究员 | 西北工业大学 | 2024 年 9 月至今

- 开发了 **NVFP4-DiT**, 一种 4 位音频引导视频扩散转换器, 实现了 **4× 内存削减**同时保持生成质量。
- 为多模扩散转换器实施了低精度量化技术, 并评估了质量与效率的权衡。
- 《NVFP4-DiT: 低成本视频生成的高效 4 位音频引导视频扩散变压器》(IEEE 多媒体汇刊, 审稿中) 一文的第一作者。
- 利用视觉、音频和时间一致性分析进行多模态深度伪造检测的研究。
- 工程硕士论文: “*检测深度伪造视频: 利用视觉、听觉和时间不一致的多模态人工智能框架*”

本科生研究员 | 西北工业大学 | 2023 年 1 月 – 2024 年 7 月

- 设计了一个分布式机密查询框架, 使用 Apache Spark 和 CKKS 同态加密。
- 通过优化分析流程, 实现了 **95% 的隐私保护**和 **20% 的性能提升**。
- 工程学士论文: “*Apache Spark 分布式机密查询协议的设计与实现*”

技术技能

语言: Python、C++、Java、SQL、Bash

LLM 系统: SGLang、vLLM、TensorRT-LLM、KV 缓存设计、PD 分解、Mooncake RDMA、etcd、NATS

GPU 与机器学习系统: CUDA、Triton、FlashAttention-2/3、FP8/FP4 量化、GEMM 优化、Nsight 系统、Nsight 计算

基础设施: Linux、Docker、Kubernetes、Slurm、RDMA Networking、TCP/IP、Prometheus、Grafana、Git、CI/CD

教育

工程硕士 软件工程 | 西北工业大学 (985/211) | 2024 年 9 月 – 2027 年 3 月

- GPA: **88/100** | 前 1% | 中国政府奖学金

计算机科学与技术工程学士 | 西北工业大学 (985/211) | 2020 年 9 月 – 2024 年 7 月

- GPA: **85/100** | 前 1% | 校长奖学金 | 最佳本科生论文奖

出版物与荣誉

出版

- 第一作者, 《NVFP4-DiT: 高效 4 位音频引导视频扩散转换器用于低成本视频生成》——IEEE 多媒体汇刊 (TMM, Q1), 审稿中

荣誉

- 中国政府奖学金 (2024-2026)
- 校长奖学金 (2020-2023)
- 最佳本科生论文奖
- 西北工业大学杰出毕业生
- 黑客松获胜者——NWPU AI 挑战赛